

Федеральное государственное образовательное бюджетное
учреждение высшего образования
«Финансовый университет при Правительстве Российской Федерации»
(Финансовый университет)

Факультет информационных технологий и анализа больших данных
Кафедра искусственного интеллекта

Выпускная квалификационная работа

на тему: «Применение трансформеров в задачах автоматического
реферирования текстов»

Направление подготовки: 01.03.02 Прикладная математика и информатика

Профиль: Анализ данных и принятие решений в экономике и финансах

Выполнил студент учебной группы

ПМ21-2

Зинев Владимир Алексеевич



Руководитель доцент, к.э.н., доцент

Маковейчук Кристина Александровна



**ВКР соответствует предъявляемым
требованиям:**

Заведующий кафедрой искусственного
интеллекта, к.э.н., доцент



М. В. Коротеев

« ____ » _____ 2025 г.

Москва 2025

Оглавление

ВВЕДЕНИЕ	3
ГЛАВА 1. АНАЛИЗ ПОДХОДОВ К АВТОМАТИЧЕСКОМУ РЕФЕРИРОВАНИЮ ТЕКСТОВ	5
1.1. Анализ задач и методов автоматического реферирования.....	5
1.2. Сравнительный анализ трансформерных моделей	10
1.3. Анализ области применения: новостные статьи	17
ГЛАВА 2. РЕАЛИЗАЦИЯ ЭКСПЕРИМЕНТА ПО ГЕНЕРАЦИИ АННОТАЦИЙ.....	24
2.1. Сбор и описание корпуса новостных текстов.....	24
2.2. Применение моделей для генерации аннотаций	33
2.3. Оценка качества и анализ результатов	40
ГЛАВА 3. РЕЗУЛЬТАТЫ И РЕКОМЕНДАЦИИ ПО ПРИМЕНЕНИЮ.....	46
3.1. Сравнение эффективности моделей в реферировании новостей.....	46
3.2. Рекомендации по применению моделей в реальной практике	60
3.3. Возможности улучшения моделей и перспективы развития	63
ЗАКЛЮЧЕНИЕ.....	69
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	71
ПРИЛОЖЕНИЕ	76

ВВЕДЕНИЕ

В современном мире объем информации, доступной в цифровом формате, стремительно увеличивается, что создает потребность в эффективных инструментах обработки и анализа текстов. Автоматическое реферирование текстов, позволяющее выделять ключевые идеи и представлять их в сжатом виде, является одной из важнейших задач в области обработки естественного языка (NLP). Развитие технологий машинного обучения, в частности архитектуры трансформеров, открывает новые перспективы для решения этой задачи с высокой точностью и качеством. Это особенно актуально для сфер, где требуется быстрая обработка больших объемов информации, таких как журналистика, научные исследования, образование и бизнес-аналитика.

Также актуальность темы исследования обусловлена несколькими факторами. Во-первых, возрастающий спрос на автоматизацию процессов анализа текстов в условиях информационного переизбытка. Во-вторых, необходимость повышения качества реферирования для обеспечения точности и информативности сжатых текстов. В-третьих, потенциал трансформеров как универсального инструмента, который может быть адаптирован к различным языкам и областям, включая специфические задачи, такие как реферирование научных статей или юридических документов.

Объектом исследования являются процессы автоматического реферирования текстов с применением языковых моделей.

Предметом исследования являются методы и модели на основе трансформеров, применяемые для генерации кратких аннотаций новостных текстов.

Цель работы: провести сравнительный анализ моделей трансформеров в задаче автоматического реферирования новостных статей и оценить их практическую применимость.

Задачи исследования:

- проанализировать современные подходы и методы автоматического реферирования текстов;
- сформировать корпус текстов и эталонных аннотаций на основе датасета Газета.Ru;
- осуществить генерацию аннотаций с использованием нескольких моделей трансформеров;
- оценить сгенерированные аннотации по метрикам ROUGE, BLEU, METEOR;
- сравнить эффективность моделей и выявить наиболее подходящие для задачи новостного реферирования.

Результат определения наиболее подходящих моделей трансформеров для задачи новостного реферирования может:

- стать основой для научных проектов различной направленности, в которых данная задача является одной из обязательных;
- использоваться в практической деятельности новостных каналов СМИ, так как позволит эффективно автоматизировать процесс новостного реферирования.

Представленная в данной работе методика применения больших языковых моделей прошла апробацию в процессе прохождения преддипломной практики в аналитическом центре финансовых исследований Научно-исследовательского финансового института Министерства финансов Российской Федерации. В аналитическом центре ведутся исследования в области применения трансформенных моделей в области NLP. Код, используемый в данной работе для обращения к большим языковым моделям, нашёл практическое применение в деятельности центра, связанной с классификацией новостных и финансовых статей.

ГЛАВА 1. АНАЛИЗ ПОДХОДОВ К АВТОМАТИЧЕСКОМУ РЕФЕРИРОВАНИЮ ТЕКСТОВ

1.1. Анализ задач и методов автоматического реферирования

Автоматическое реферирование текстов — это процесс извлечения наиболее важной информации из текста и формирования его сокращённого представления (реферата) с сохранением ключевых смысловых элементов, осуществляемый с помощью алгоритмов обработки естественного языка. Данный процесс направлен на создание краткого, но информативного содержания текста, позволяющего пользователю быстро ознакомиться с его основной идеей без необходимости полного прочтения оригинального материала [6, 8].

Особенно актуально автоматическое реферирование в контексте новостей, поскольку оно позволяет оперативно справляться с огромными объемами информации, снижая информационную перегрузку и значительно ускоряя доступ пользователей к сути событий. Эта технология критически важна для быстрого мониторинга медиапространства, эффективного поиска релевантной информации и адаптации новостного контента для различных платформ, что значительно экономит время и ресурсы как для индивидуальных потребителей, так и для организаций, работающих с новостями [1, 6].

Подходы к автоматическому реферированию текста делятся на экстрактивное (извлекающее) реферирование и абстрактивное (генерирующее) реферирование [5, 11].

Основная цель экстрактивных методов заключается в выявлении и выделении наиболее значимых предложений в заданном тексте. Важнейшие элементы оригинального текста собираются в краткое изложение [9, 17].




Рисунок 1.1 - Визуализация экстрактивного реферирования

Для экстрактивного реферирования было разработано множество алгоритмов, каждый из которых использует уникальный метод извлечения и ранжирования предложений. Эти методы включают:

- статистический анализ;
- семантические подходы;
- графовые методы [6, 8].

Одним из первых предложенных методов экстрактивного реферирования является метод Луна (Luhn). Он ранжирует каждое предложение в тексте на основе частоты появления наиболее значимых слов и их относительного расположения внутри предложения, используя методы статистического анализа. Для формирования итогового реферата выбираются предложения с наивысшими оценками. Однако у этого метода есть большой недостаток — он игнорирует связи между словами или фразами и сосредотачивается только на отдельных словах [9, 17].

Одним из первых методов, попытавшихся моделировать семантические связи между словами и выделять ключевые темы в тексте, был латентно-семантический анализ (LSA, Latent Semantic Analysis). Подход LSA, предложенный Гонгом и Лю (Gong & Liu) для задачи реферирования текста, моделирует документ в виде матрицы "термин-предложение", представляющей частоту встречаемости каждого слова в каждом предложении текста. Далее для ранжирования и выделения наиболее значимых предложений применяется метод сингулярного разложения

матрицы (SVD, Singular Value Decomposition), который извлекает наиболее значимые семантические компоненты документа.

Другим методом экстрактивного реферирования, который решает некоторые недостатки предыдущих подходов, является использование графовых алгоритмов, позволяющих создавать масштабируемые и быстрые рефераты. Одним из самых известных и старых графовых методов является TextRank. В этом методе документ представляется в виде взвешенного графа предложений:

- узлы графа представляют собой отдельные предложения текста;
- рёбра графа отражают связи между предложениями на основе их схожести (например, по степени совпадения слов в них) [8].

После построения графа каждое предложение оценивается с учетом его связей с другими предложениями с использованием алгоритма центральности PageRank. В результате реферат формируется из предложений, получивших наивысший рейтинг. Число извлекаемых предложений может быть задано пользователем как параметр настройки.

Поскольку экстрактивные методы используют простые эвристики для выделения и объединения наиболее значимых предложений без учёта грамматических и синтаксических правил, они имеют серьёзный недостаток: рефераты, полученные таким способом, часто теряют связность и читаемость. Именно поэтому стало необходимым развитие абстрактных методов. Для создания рефератов, которые будут связными и иметь смысл, требуется учитывать в каком контексте используются слова. Таким образом, необходимы модели, которые генерируют новые предложения так, как это делает человек, перефразируя информацию [6, 11].




Рисунок 1.2 - Визуализация абстрактного реферирования

В прошлом было предложено множество моделей абстрактного реферирования, включая методы, основанные на графах, правилах и семантическом моделировании. Однако многие из этих ранних моделей не использовали достижения глубинного обучения, которые значительно улучшили качество выполнения различных задач NLP [14, 16].

Современные подходы к автоматическому реферированию, особенно абстрактное реферирование, которое генерирует новые предложения для создания более связных и лаконичных резюме, активно используют возможности глубоких нейросетевых моделей. Если на ранних этапах развития применялись такие архитектуры, как рекуррентные нейронные сети (RNN) или сверточные нейронные сети (CNN) (иногда в сочетании с механизмами внимания), то сегодня наиболее передовые результаты достигаются с помощью моделей, основанных на архитектуре Трансформера. Трансформер, по сути, является разновидностью архитектуры энкодер-декодер, в которой ключевую роль играет механизм внимания. Отказавшись от рекуррентных слоев, трансформеры стали гораздо более эффективными в обработке длинных текстовых последовательностей и выявлении сложных взаимосвязей между словами и фразами на большом расстоянии друг от друга [11, 19]. На базе архитектуры Трансформера были разработаны и обучены на огромных текстовых корпусах мощные предварительно обученные языковые модели (например, T5, BART, PEGASUS и более поздние и крупные модели). Эти модели, будучи дообученными на задачах реферирования,

демонстрируют выдающиеся способности к пониманию исходного текста и генерации высококачественных, релевантных и связных абстрактных резюме новостных статей [19, 22, 23].

Таким образом, автоматическое реферирование, основанное на современных глубоких нейросетевых моделях, в первую очередь на архитектуре Трансформера и производных от нее предварительно обученных моделях, является неотъемлемым инструментом для эффективной работы с возрастающим объемом новостной информации, позволяя быстро извлекать ключевую суть и принимать обоснованные решения в условиях информационного изобилия [19, 37].

1.2. Сравнительный анализ трансформерных моделей

В данной работе будет проведён сравнительный анализ 10 трансформерных моделей. Для начала сравним эти модели по следующим пунктам:

- язык, который «понимает» модель
- обучающая выборка модели
- количество параметров
- источник для получения доступа к модели
- задачи, решаемые моделью

Таблица. 1.1 Сравнительный анализ моделей

Модель	Язык	Обучающая выборка	Кол-во параметров	Доступ	Область применения
IlyaGusev/rubert_ext_sum_gazeta	RU	Новости с сайта Газета.РУ	~180 млн	Hugging Face	Экстрактивное реферирование новостей
IlyaGusev/rut5_base_sum_gazeta	RU	Новости с сайта Газета.РУ	~220 млн	Hugging Face	Абстрактное реферирование новостей
IlyaGusev/rugpt3medium_sum_gazeta	RU	Новости с сайта Газета.РУ	~355 млн	Hugging Face	Абстрактное реферирование новостей
GigaChat-2 (Lite)	Многоязычный	Большая, разнородная (веб-текст, код, книги и др.)	Неизвестно (млрд)	API, Пользовательский интерфейс	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование и др.
Yandex GPT 5 Pro	Многоязычный	Большая, разнородная (веб-текст, код,	Неизвестно (млрд)	API, Пользовательский интерфейс	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование,

		книги и др.)			решение сложных задач и др.
Yandex GPT 5 Lite	Многоязычный	Большая, разнородная (веб-текст, код, книги и др.)	~8 млрд	Hugging Face, API, Пользовательский интерфейс	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование и др.
meta-llama/llama-4-scout-17b-16e-instruct	Многоязычный	Большая, разнородная (веб-текст, код и др.)	~17 млрд	Hugging Face, API	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование и др.
deepseek r1 distill llama 70b	Многоязычный	Большая, разнородная (веб-текст, код и др.)	~70 млрд	Hugging Face, API	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование, решение сложных задач и др.
Mistral 7B latest	Многоязычный	Большая, разнородная (веб-текст, код и др.)	~7 млрд	Hugging Face, API, Пользовательский интерфейс	Генерация текста, диалоги, ответы на вопросы, программирование, реферирование и др.
Mistral Large latest	Многоязычный	Большая, разнородная (веб-текст, код и др.)	~123 млрд	API, Пользовательский интерфейс	Генерация текста, диалоги, программирование, суммирование, решение сложных задач и др.

Первые три модели из таблицы 1.1 являются узкоспециализированными трансформерами, решающими исключительно задачу реферирования. Остальные же модели являются большими языковыми моделями, решающими широкий спектр задач.

Далее рассмотрим архитектуру данных моделей, их сильные и слабые стороны.

1) IlyaGusev/rubert_ext_sum_gazeta

Базовая архитектура: transformer-encoder (модификация BERT)

Ключевые особенности и сильные стороны:

- высокое качество понимания и выделения ключевых предложений благодаря глубокому контекстному представлению;
- стабильность и воспроизводимость результатов экстрактивного суммирования;
- небольшой размер (по сравнению с генеративными LLM), быстрый вывод на CPU.

Ограничения и слабые стороны:

- ее умеет генерировать новые формулировки — только выделяет уже существующие фрагменты текста;
- узкая зона применения (только экстрактивное суммирование);
- фиксированная длина входа, отсутствие автогрессивного декодера [6].

2) IlyaGusev/rut5_base_sum_gazeta

Базовая архитектура: Transformer-encoder-decoder (T5-base)

Ключевые особенности и сильные стороны:

- генеративное (абстрактивное) суммирование: умеет перефразировать, обобщать и сжато излагать мысль;
- универсальная text-to-text архитектура, легко адаптируется к другим задачам (перевод, вопрос-ответ и т.п.);
- умеренный размер (≈ 220 М параметров) — компромисс между качеством и производительностью,

Ограничения и слабые стороны:

- может «галлюцинировать» факты или дополнять информацию, не представленную в тексте;
- требует больше ресурсов для вывода (GPU/TPU) по сравнению с экстрактивными моделями [22].

3) IlyaGusev/rugpt3medium_sum_gazeta

Базовая архитектура: transformer-decoder, автогрессивный (аналог GPT-3 medium)

Ключевые особенности и сильные стороны:

- сильная генеративная способность: может выдавать плавный текст, адаптируясь к стилю газета.RU;
- инструкция-ориентированность: дообучена на задаче суммирования, но при необходимости может решать и другие генеративные задачи;
- хорошо работает в автозаполнении и продолжении заданного контекста.

Ограничения и слабые стороны:

- большой «размер» и более высокие требования к памяти и скорости вывода, чем у T5-base;
- риск генерации нерелевантного или фактически неверного текста (галлюцинации);
- ограниченная способность к точному извлечению фактов (нет экстрактивного компонента) [19].

4) GigaChat-2 (Lite)

Базовая архитектура: Transformer-decoder, автогрессивный, кастомная версия Sber AI

Ключевые особенности и сильные стороны:

- оптимизирована для диалоговых задач: ведёт беседу, отвечает на вопросы, сохраняет контекст
- «Lite»-версия снижена в размерах для более быстрой работы
- обучена на разнообразных диалоговых и инструкционных корпусах

Ограничения и слабые стороны:

- упрощённая (Lite) версия уступает полноразмерной в глубине понимания и длине контекста
- могут проявляться «провалы» в специализированных доменах за пределами диалогов

- риски генерации некорректных фактов и необоснованных рассуждений

5) Yandex GPT-5 Pro

Базовая архитектура: transformer-decoder, автогрессивный, многомодальный (частично) LLM от Яндекса

Ключевые особенности и сильные стороны:

- высокая точность и глубина ответов
- поддержка инструкций («instruct-tuning») для решения широкого круга задач: от генерации текстов до анализа данных
- интеграция с сервисами Яндекса (поиск, словари, база знаний)

Ограничения и слабые стороны:

- нет открытого доступа к архитектуре
- высокие требования к ресурсам при локальном запуске (в основном предназначена для облачных API)
- есть ограничения по содержанию и политике модерации внутри экосистемы Яндекса

6) Yandex GPT-5 Lite

Базовая архитектура: Упрощённая версия GPT-5 Pro (Transformer-decoder)

- ключевые особенности и сильные стороны:
- быстрее отвечает и потребляет меньше памяти, чем Pro-версия
- сохраняет большинство инструкционно-ориентированных навыков Pro версии
- более доступна для интеграции в легковесные продукты

Ограничения и слабые стороны:

- более низкое качество генерации по сравнению с Pro версией
- может хуже справляться с глубокой аналитикой и длинными контекстами
- риск галлюцинаций

7) meta-llama/llama-4-scout-17b-16e-instruct

Базовая архитектура: transformer-decoder,

Ключевые особенности и сильные стороны:

- баланс между размером и способностями
- инструкция-ориентированное дообучение улучшает следование указаниям пользователя
- открытый доступ и возможность самостоятельного дообучения

Ограничения и слабые стороны:

- ограниченная контекстная длина (обычно ~4–8 к токенов)
- всё ещё слабее в генерации кода и узкоспециализированных знаний по сравнению с «топовыми» 70B+ моделями
- риск галлюцинаций без дополнительной верификации

8) deepseek r1 distill llama 70b

Базовая архитектура: Transformer-decoder, дистилляция оригинального LLaMA 70 B до более компактного «release 1»

Ключевые особенности и сильные стороны:

- сохраняет большую часть качества оригинала 70 B при меньших ресурсных затратах
- подходит для задач, требующих глубокой генерации и понимания (научные тексты, код, сложные инструкции)
- более лёгкий запуск на современных серверных GPU по сравнению с полноразмерным 70 B

Ограничения и слабые стороны:

- несмотря на дистилляцию, остаётся «тяжёлой» моделью
- дистилляция может приводить к потере части знаний и нюансов генерации
- требует тщательной настройки гиперпараметров для достижения идеального компромисса скорости/качества

9) mistral-8b-latest

Базовая архитектура: transformer-decoder, 8 B параметров

Ключевые особенности и сильные стороны:

- оптимизирована для скорости вывода и эффективности использования памяти
- хороший баланс качества в генерации текста при небольших ресурсах
- открытый релиз, легко интегрируется и дообучается

Ограничения и слабые стороны:

- качество ответов может быть хуже, чем у моделей с 20–70 B
- ограниченная способность обрабатывать очень длинные контексты
- более низкая устойчивость к сложным логическим задачам

10) mistral-large-latest

Базовая архитектура: transformer-decoder

Ключевые особенности и сильные стороны:

- высокое качество генерации и понимания текста, близкое к «топовым» LLM
- эффективная архитектура, оптимизированная под современные GPU и относительно быстрая генерация
- открытый доступ, сообщество активно развивает и дообучает

Ограничения и слабые стороны:

- требует серьёзных вычислительных ресурсов
- риск «галлюцинаций»
- слишком большой размер модели

1.3. Анализ области применения: новостные статьи

В условиях стремительного роста объёмов информации особую актуальность приобретает умение быстро ориентироваться в новостной повестке. Одним из инструментов, способствующих эффективному восприятию и обработке информации, является реферирование новостей.

Под реферированием новостей понимается краткая, структурированная передача основной сути новостного материала с акцентом на ключевые факты, без искажения исходного смысла. Такая форма представления информации позволяет читателю в сжатые сроки получить представление о содержании публикации, не углубляясь в полный текст.

Актуальность темы обусловлена несколькими факторами. Во-первых, это информационная перегрузка, с которой сталкивается современный человек: ежедневно публикуются десятки тысяч новостей из разных источников, охватывающих самые различные сферы — от политики и экономики до науки и культуры. Во-вторых, наблюдается резкий рост числа медиаплатформ и каналов распространения информации — от традиционных СМИ до социальных сетей и мессенджеров. И, наконец, изменяются форматы потребления контента: всё больше пользователей отдают предпочтение кратким, лаконичным формам подачи информации, таким как дайджесты, карточки или короткие посты.

В этих условиях реферирование становится не просто вспомогательной функцией, а необходимым элементом информационной экосистемы. Оно позволяет систематизировать данные, облегчает навигацию по потоку новостей и способствует более осознанному выбору источников для дальнейшего ознакомления.

Основной целью реферирования новостей является предоставление читателю сжатой, но содержательной информации, достаточной для понимания сути события без необходимости обращения к полному тексту. Это

особенно важно в условиях ограниченного времени и высокой плотности информационного потока.

К числу ключевых задач реферирования можно отнести следующие:

- Экономия времени аудитории. Современный потребитель информации зачастую не имеет возможности читать полные тексты всех новостей. Рефераты позволяют быстро охватить широкий спектр тем и выбрать те, которые представляют наибольший интерес для дальнейшего ознакомления.

- Облегчение ориентации в новостной повестке. Краткие версии материалов упрощают восприятие сложной или объёмной информации, выделяя главное — факты, ключевые события, выводы.

- Снижение когнитивной нагрузки. При значительном объёме входящей информации краткие тексты позволяют избежать переутомления и снижения внимания, способствуют лучшей концентрации на сути.

- Повышение доступности информации для широкой аудитории. Рефераты делают новости более понятными и удобными для восприятия в различных форматах: на мобильных устройствах, в мессенджерах, социальных сетях.

- Адаптация контента под разные каналы распространения. Одно и то же сообщение может быть представлено в виде краткой заметки, карточки, push-уведомления или даже голосового дайджеста — в зависимости от потребностей целевой аудитории и технических возможностей платформы [6, 8, 16].

Таким образом, реферирование играет стратегическую роль в медиапространстве: оно не только облегчает потребление информации, но и способствует формированию более осознанного, критически мыслящего читателя.

В профессиональной журналистике реферирование применяется как один из базовых инструментов организации новостного контента. Оно

используется не только для удобства читателя, но и как способ структурировать информационный поток внутри редакции.

Во многих агентских и новостных форматах, особенно в лентах срочных сообщений, используются короткие, лаконичные публикации, в которых излагаются только основные факты без подробных комментариев и анализа. Такие материалы являются своеобразными «рефератами» более полных новостных статей.

Пример: новостные агентства вроде Reuters, Associated Press, ТАСС активно применяют данный подход — каждая новость начинается с абзаца, в котором изложена суть, а затем следует уточнение деталей.

Также многие редакции публикуют ежедневные или еженедельные дайджесты - подборки ключевых новостей, изложенных в краткой форме. Такие форматы особенно удобны для читателей, не следящих за повесткой постоянно, но желающих оставаться в курсе основных событий. Пример: «Медуза», «РБК», «Коммерсантъ» предлагают утренние или вечерние сводки с краткими аннотациями к каждой новости.

Более того, журналистика активно использует приёмы реферирования уже на уровне заголовков. Часто заголовок и подзаголовок представляют собой краткое изложение сути материала, позволяющее понять, о чём пойдёт речь, ещё до открытия статьи. Это особенно важно в цифровых форматах, где конкуренция за внимание читателя велика.

Редакции также применяют реферирование для внутреннего документооборота: при подготовке лонгридов, аналитических материалов или спецпроектов создаются краткие аннотации, по которым главные редакторы или продюсеры принимают решение о выпуске, формате и продвижении материала.

Таким образом, в журналистике реферирование выполняет сразу несколько функций: облегчает восприятие новостей, повышает эффективность редакционной работы и способствует увеличению вовлечённости аудитории.

Говоря о важности реферирования новостных статей, нельзя обойти стороной телеграм-каналы. Телеграм-каналы сегодня стали одними из главных игроков на рынке новостей, особенно в странах с активной цифровой аудиторией. Их особенность — оперативность, лаконичность и неформальный стиль подачи. В этих условиях реферирование играет ключевую роль, позволяя доносить информацию быстро и ёмко.




Рисунок 1.3 - Анализ топ 100 телеграмм каналов

Согласно исследованию Mediascope, результаты которого, представлены на рисунке 1.3, около 55% телеграмм каналов прямо или косвенно связаны с новостями. В большинстве популярных телеграм-каналов новость подаётся в виде короткого поста — от одного до трёх абзацев, где изложена основная суть события. Подобный формат по своей природе является реферативным, поскольку автор отбирает только важные детали, избегая избыточных пояснений или второстепенной информации. Пример: канал «Mash» публикует инциденты, происшествия и события в формате кратких сводок, часто добавляя фото или видео для наглядности.

Многие каналы придерживаются принципа «одна новость - один абзац», позволяя читателю быстро «пролистывать» повестку, как ленту. Это удобно и соответствует современным привычкам потребления контента - особенно в условиях мобильности и постоянной занятости аудитории. «RT на русском»

используют именно такой подход, делая акцент на кратком пересказе новостей.

Реферирование также служит задачам популяризации и объяснения сложных новостей — например, в сферах экономики, науки или международной политики. Каналы часто пересказывают аналитические статьи, переводят экспертные мнения в доступную форму. Пример: канал «Незыгарь» и другие политические блоги реферируют большие массивы информации в короткие посты, делая акцент на смысле, а не на форме подачи.

Также задача автоматического реферирования является неотъемлемой технологической и функциональной частью работы новостных агрегаторов. Новостные агрегаторы — такие как Google News, Яндекс.Новости, СМІ2 и другие — представляют собой автоматизированные платформы, собирающие материалы из разных источников и предоставляющие их пользователю в сжатом виде.

Один из ключевых механизмов агрегаторов — это генерация кратких аннотаций к каждой новости. Эти аннотации, как правило, представляют собой автоматизированные рефераты, созданные на основе алгоритмов обработки естественного языка. Пример: Google News формирует сниппеты - короткие фрагменты текста, отражающие суть публикации, - на основе первых абзацев или выделенных ключевых фраз.

Пользователь, просматривая агрегатор, видит множество новостей из разных источников, и краткие рефераты позволяют быстро сориентироваться в содержании, не переходя по каждой ссылке. Это существенно сокращает время поиска нужной информации и повышает удовлетворённость взаимодействием с платформой. Агрегаторы часто отображают сразу несколько версий одной и той же новости от разных источников. В таких случаях краткое содержание становится важным элементом конкуренции за клики: чем точнее и интереснее сформулирован реферат, тем выше вероятность, что пользователь выберет именно этот материал.

Таким образом, в агрегаторах реферирование выполняет двойную функцию — оно упрощает доступ к информации для пользователя и одновременно служит инструментом повышения эффективности контента в условиях конкуренции за внимание.

Несмотря на очевидные преимущества, практика реферирования новостей сопряжена с рядом проблем и ограничений, которые затрагивают как качество информации, так и восприятие аудитории. Рассмотрим основные из них.

1. Потеря контекста.

Одной из главных угроз при реферировании является искажение смысла из-за чрезмерного упрощения. Краткий пересказ может опустить важные детали, которые критичны для понимания сути события или позиции сторон. Особенно это актуально для сложных тем — юридических, политических, научных.

2. Субъективность и манипуляция.

При ручном реферировании всегда существует риск влияния личной интерпретации редактора или автора, особенно если пересказ проводится с целью формирования определённого мнения. Это может привести к манипуляциям, подмене фактов или неполному отражению позиции участников событий.

3. Кликбейт и искажение ради внимания.

В стремлении привлечь внимание аудитории многие платформы используют кликбейтные заголовки и выжимки, которые, по сути, являются искажёнными рефератами. Подобные практики подрывают доверие к новостному контенту, формируют у аудитории ошибочные представления и снижают уровень медиаграмотности.

4. Качество автоматических алгоритмов.

Хотя технологии автоматического реферирования активно развиваются, они всё ещё далеки от идеала. Алгоритмы могут:

- выделять несущественные детали

- терять логическую связность
- не учитывать эмоциональную или политическую окраску текста.

Это особенно важно в контексте новостей, где важны не только факты, но и их тональность, подтексты и формулировки.

ГЛАВА 2. РЕАЛИЗАЦИЯ ЭКСПЕРИМЕНТА ПО ГЕНЕРАЦИИ АННОТАЦИЙ

2.1. Сбор и описание корпуса новостных текстов

Набор новостных статей и их рефераты были взяты с платформы Hugging Face. На данной платформе он имеет название : “IlyaGusev/gazeta”. Датасет содержит примерно 61 тысячу статей в тренировочном наборе и почти 7 тысяч в тестовом. Статьи и их рефераты были взяты с сайта издательства Газета.Ru. Тексты и рефераты были написаны непосредственно журналистами издательства.

Из-за ограничений в вычислительных мощностях из всей совокупности статей издательства Газета.RU будет случайным образом выбрано 500 статей. Это является обоснованным подходом, поскольку случайный отбор гарантирует репрезентативность выборки и минимизирует вероятность систематической ошибки. Такой размер выборки позволяет с достаточной статистической мощностью выявлять существенные закономерности и получать надёжные результаты.

Рассмотрим распределение слов и предложений в имеющейся выборке статей (см. рис. 2.1).




Рисунок 2.1 - Распределение слов/предложений исходных статей

Распределение по количеству слов показывает, что большинство статей имеет объём в диапазоне от 350 до 900 слов, при этом наиболее частым оказывается интервал от 400 до 600 слов. Такой разброс свидетельствует о том, что новостные тексты, как правило, следуют установленным редакционным стандартам, обеспечивающим достаточную информативность при умеренной длине. Это позволяет читателю быстро воспринять основной контекст события, не перегружаясь избыточной информацией.

Распределение предложений демонстрирует схожую закономерность: большинство статей в диапазоне от 20 до 40 предложений. Это обеспечивает как полноту изложения ключевых фактов, так и логическую последовательность подачи материала, что соответствует требованиям профессиональной журналистики. При этом наличие разброса в сторону более коротких или более длинных статей указывает на вариативность тематики и жанрового разнообразия публикуемых материалов.

В совокупности, полученные графики подтверждают, что исходные статьи газета.ru обладают чётко выработанной структурой, где соблюдается

баланс между объёмом текста и его информативностью. Наблюдаемая концентрация значений в определённых диапазонах демонстрирует стандартизацию письменной речи в новостном медиа, позволяющую эффективно доносить суть событий до аудитории. Такой подход, наряду с высокими редакционными стандартами, гарантирует как качество подачи, так и оперативность распространения информации.

Далее рассмотрим распределение слов и предложений рефератов журналистов (см. рис. 2.2).




Рисунок 2.2 - Распределение слов/предложений рефератов

Наблюдаемые графики демонстрируют частотное распределение длины рефератов по двум метрикам: числу слов и числу предложений. При визуальном анализе видно, что количество слов преимущественно варьируется в диапазоне 30–50, а большая часть рефератов содержит в среднем 3–4 предложения. Данные результаты свидетельствуют о тенденции журналистов «Газета.Ру» формировать рефераты умеренного объёма, что может быть оптимальным для оперативного восприятия и обеспечения содержательности при сокращённом формате.

Облако "Рефераты":

1. Ключевые слова: Наиболее частотные слова здесь — РОССИЯ, ПРЕЗИДЕНТ, США, ГОД, ВРЕМЯ, НОВЫЙ, ЗАЯВЛЯТЬ, ЭКСПЕРТ, ВЛАДИМИР.

2. Другие заметные слова: УКРАИНА, МОСКВА, ВОЕННЫЙ, ВЛАСТЬ, ГОСУДАРСТВО, СЛОВО, РОССИЙСКИЙ, ОТМЕЧАТЬ, СООБЩАТЬ, ЧЕЛОВЕК, АМЕРИКАНСКИЙ, БАЙДЕН, ПУТИН, ТРАМП, ПОМОЩЬ, КОМПАНИЯ, COVID, КОРОНАВИРУС, ПЕРВЫЙ, КИЕВ.

3. Тематика: Политическая тематика также доминирует, но кажется более сфокусированной. Появляются конкретные имена (Владимир, Байден, Путин, Трамп) и страна (США), которые гораздо заметнее, чем в первом облаке. Также выделяются конкретные темы (COVID/Коронавирус) и термины, связанные с анализом или действиями (эксперт, военный, помощь).

Оба облака показывают высокую частотность слов, связанных с Россией, политикой (президент, власть, заявлять), временем (год, время) и международными отношениями (Украина, американский).

Различия:

– Облако "Рефераты" более конкретизировано. В нем акцентированы США и имена политических лидеров (Владимир, Байден, Путин, Трамп).

– В рефератах чаще встречаются слова "эксперт" и "военный", а также упоминается COVID/Коронавирус.

– Общие слова, такие как "человек" и "страна", менее заметны в рефератах по сравнению с исходными статьями.

– Это говорит о том, что рефераты (краткие изложения) концентрируются на ключевых субъектах (Россия, США, конкретные лидеры), основных событиях (COVID) и оценках (эксперт), отсеивая более общие слова, характерные для полных текстов статей.

Проанализируем как зависят размеры рефератов (в словах) в зависимости от исходных статей (см. рис. 2.4).




Рисунок 2.4 - График объёмов слов рефератов и статей

На графике на горизонтальной оси отложено число слов в исходных текстах новостных статей, а по вертикальной — число слов в соответствующих рефератах. Из полученного графика можно сделать следующие выводы:

- **Независимость от объёма исходного текста:** Несмотря на то, что статьи газета.ru демонстрируют значительный разброс по длине (обычно порядка 400–800 слов), размер рефератов остаётся строго ограниченным (ориентировочно 30–60 слов). Это позволяет предположить, что при составлении рефератов журналисты руководствуются жёсткими редакционными требованиями, что обеспечивает единообразие и краткость итоговой информации.

– Ограничение размера сводки: Постоянство количества слов в рефератах указывает на применение фиксированных стандартов, характерных для редакционной политики газета.ru. Такое ограничение позволяет быстро донести суть новости читателю, не перегружая его деталями, присутствующими в полном тексте.

Проанализируем как зависят размеры рефератов (в предложениях) в зависимости от исходных статей (см. рис. 2.5).




Рисунок 2.5 - График кол-ва предложений рефератов и статей

На данном графике по горизонтальной оси представлено число предложений в исходном тексте, а по вертикальной — количество предложений в реферате. Из полученного графика можно сделать следующие выводы:

– Фиксированное число предложений: Анализ показывает, что даже при значительном разнообразии структурных особенностей исходных статей (например, текст может содержать до 80 предложений), итоговые рефераты в большинстве случаев содержат всего 1–5 предложений с преобладанием 3–4.

Это свидетельствует о том, что при подготовке рефератов журналисты газета.Ру используют стандартизированный формат, направленный на сжатие информации до нескольких ключевых утверждений.

– Стандартизация формата: Стабильность количества предложений в рефератах подчёркивает, что итоговый формат выбирается с учётом редакционных норм, позволяющих обеспечить одновременно информативность и краткость, что особенно важно для современных новостных публикаций.

Анализ графиков на рисунках 2.3 и 2.4 демонстрирует, что объем рефератов в словах и в предложениях, подготовленных журналистами газета.Ру, остаются в строгих рамках независимо от первоначального объема исходных статей. Полученные результаты позволяют предположить, что формирование данных рефератов регулировалось строгими редакционными стандартами, обеспечивающими высокую степень сжатия информации при сохранении её ключевого содержания. Такой подход характерен для профессиональной журналистики, где важна оперативность передачи главных новостных фактов при минимальной текстовой нагрузке.

Пример самой короткой статьи (254 слова) и её реферата (44 слова):

– Оригинальный текст:

В Мурманской области в ходе совместных тренировочных занятий Росгвардии с военнослужащими спецподразделений Министерства обороны в четверг, 20 мая, погибли два бойца СОБР «Росомаха». ЧП произошло на западном берегу Кольского залива в ходе беспарашютного десантирования с борта вертолета на палубу корабля, сообщает «Звезда». Как пишет портал «СеверПост», трагедия произошла из-за оборвавшегося троса, закрепленного на вертолете. Один силовик погиб непосредственно на учениях, второй был госпитализирован и скончался в больнице. В этой связи 305-й военный следственный отдел Следственного комитета РФ начал проверку. «Проверка

проводится в рамках сообщения о преступлении, предусмотренном ч. 3 ст. 293 УК РФ («Халатность»), — говорится в сообщении ВСУ СК по Северному флоту. Там напомнили, что халатность, то есть ненадлежащее исполнение должностным лицом своих обязанностей вследствие недобросовестного или небрежного отношения к службе, повлекшее смерть нескольких человек, предполагает, среди прочего, семилетний срок заключения в качестве наказания. При этом в следственном управлении отказались сообщать подробности происшествия, а также кто может быть фигурантом дела. «Учитывая, что процессуальное решение о преступлении не принято, разглашение сведений о ходе доследственной проверки может повлечь нарушение прав и законных интересов участников уголовного судопроизводства. В связи с этим, указанные сведения разглашению не подлежат», — заявил первый заместитель руководителя ВСУ СК России по СФ Иван Антонов. В территориальном управлении Росгвардии заявили, что родственникам погибших будет оказана необходимая помощь. «КП-Мурманск» со ссылкой на источники сообщает, что одного из погибших звали Сергей Фундамент, он был заместителем командира отряда специального назначения «Айсберг». Он служил в Чечне, с лучшей стороны проявил себя в ходе выполнения спецопераций против боевиков, получил множество наград, в том числе — два ордена Мужества.

– Реферат:

Следственное управление по Северному флоту начало проверку гибели двух бойцов СОБР «Росомаха» на тренировочных учениях на берегу Кольского залива. Причиной трагедии стал обрыв троса в ходе беспарашютного десантирования с борта вертолета на палубу корабля. В Росгвардии заявили, что родственникам погибших будет оказана необходимая помощь.

2.2. Применение моделей для генерации аннотаций

Доступ к следующим моделям был получен через платформу Hugging Face. Через неё были загружены архитектуры моделей и их веса. Далее в среде разработки google colab с помощью ограниченных по времени, но бесплатных мощностей GPU были запущены соответствующие модели и получены рефераты от каждой из них:

- 1) IlyaGusev/rubert_ext_sum_gazeta,
- 2) IlyaGusev/rut5_base_sum_gazeta
- 3) IlyaGusev/rugpt3medium_sum_gazeta

Обработка 500 статей и получение рефератов для каждой из моделей заняла разное кол-во времени. Модель rubert_ext_sum_gazeta обработала все статьи всего за 34 секунды. Столь быстрая обработка объясняется тем, что экстрактивные методы дают быстрее результат, потому что они просто метят уже готовые отрывки в тексте, а не генерируют новый текст «с нуля».

Модель rut5_base_sum_gazeta потратила на обработку 9 минут 13 секунд, а rugpt3medium_sum_gazeta 27 минут. RuT5_base_sum_gazeta работает в ~3 раза быстрее, потому что «энкодер–декодер» один раз параллельно кодирует весь текст и затем быстро декодирует итог, а rugpt3medium_sum_gazeta как «декодер-только» автогенерирует каждый новый токен по нарастающему префиксу (каждый раз прогоняя через всю сеть), к тому же при большем числе параметров и более тяжёлых стратегиях поиска.

Доступ к большим таким языковым моделям, как:

- 1) meta-llama/llama-4-scout-17b-16e-instruct
- 2) deepseek r1 distill llama 70b

был получен через API платформы Groq Cloud. Groq Cloud – это облачная платформа, обеспечивающая высокопроизводительное выполнение моделей машинного обучения через удобный программный интерфейс. С её помощью

можно управлять и запускать вычислительно интенсивные задачи, связанные с обработкой естественного языка, а также интегрировать и масштабировать модели в режиме реального времени. Данная платформа имеет бесплатный режим с ограничением в число запросов в минуту и ограничениями по токенам.

Системный промт для моделей : «You are a professional assistant specializing in summarizing Russian-language texts. Your summaries should always be written in natural, fluent Russian, using 3–4 complete sentences and approximately 45 words. Focus on preserving the core ideas without excessive shortening or omission. Always write the summary in Russian.»

Он был написан на английском, потому что большая часть «системных» и «instruction-tuning» датасетов у LLM собрана именно на английском, поэтому модель лучше понимает и исполняет инструкции на нём.

Пользовательский запрос : «Перескажи следующий текст на русском языке в виде 3–4 полных предложений, объёмом примерно 45 слов. Сделай пересказ кратким, но содержательным.\nСтатья:»

Обработка 500 статей для модели llama-4-scout-17b-16e-instruct заняла примерно 45 минут. Она могла занять значительно меньше времени с подпиской, но в таком случае за использование этой модели пришлось бы заплатить около 4 центов. Это примерно 3,154 рубля (доллар = 83)

Обработка 500 статей для модели deepseek r1 distill llama 70b заняла 1 час 11 минут из-за ограничений бесплатной версии. С подпиской за использование этой модели пришлось бы заплатить около 50 центов. Это примерно 41,5 рубля (доллар = 83)

Думал на протяжении пары секунд

Вторая модель медленнее прежде всего из-за четырёхкратного превышения числа параметров ($\approx 70\text{ B}$ vs 17 B) и более тяжёлых матричных операций, даже после дистилляции. Также deepseek r1 distill llama 70b – это модель с поэтапным рассуждением, что добавляет генерацию сотен промежуточных токенов и дополнительные проходы через сеть, что ещё

сильнее растягивает время. В совокупности более тяжёлая архитектура, сдержанные облачные ресурсы и накладные расходы на рассуждения повышают время обработки с 45 минут до 1 ч 11 мин и делают модель «дороже».

Доступ к большим таким языковым моделям, как:

- 1) mistral-8b-latest
- 2) mistral-large-latest

был получен через API на платформе Mistral AI. Время обработки 500 статей заняло 50 минут и 74 минуты соответственно. Вторая модель обрабатывала статьи дольше из-за того, что в ней больше параметров и она является более продвинутой версией первой.

Системный запрос: 'You are a professional assistant specializing in summarizing Russian-language texts. Always write the summary in Russian.'

Пользовательский запрос: 'Summarize text nearly 45 words. Answer on russian\nСтатья:'

Доступ к использованию модели **GigaChat-2(Lite)** через API был получен с платформы: <https://developers.sber.ru/>

Время обработки 500 статей заняло 4 минуты и 5 секунд. На обработку и получение ответов было потрачено примерно 200 тысяч токенов. Цена 5 миллионов токенов на данной платформе = 1000 рублей. Следовательно, примерная цена обработки = 40 рублей. У данной платформы нет ограничений на кол-во запросов в минуту, но есть ограниченное кол-во токенов для обработки. Но, что более важно, у платформы достаточно чувствительная цензура к новостным статьям.

Из 500 статей я получил рефераты лишь 188. То есть платформа заблокировала 312 запросов. При отсутствии цензуры получение всех ответов заняло бы примерно 11 минут. Ответ модели при блоке чередуется между тремя :

- 'Как у нейросетевой языковой модели у меня не может быть настроения, но почему-то я совсем не хочу говорить на эту тему.'
- 'Не люблю менять тему разговора, но вот сейчас тот самый случай.'
- 'Что-то в вашем вопросе меня смущает. Может, поговорим на другую тему?'

Рассмотрим облако слов, основанное на частоте слов, заблокированных текстов, чтобы понять, что могло стать причиной блокировки (см. рис.2.6).




Рисунок 2.6 - Облако слов цензурированных текстов модели GigaChat

В данном облаке слов можно заметить слова: [украина, военный, трамп, байден, крым, власть, американский, ракета, нато]. Спросим у лучшей модели

Сбербанка GigaChat2 Max является ли упоминание этих слов поводом для цензуры напрямую через пользовательский интерфейс (см. рис. 2.7).




Рис. 2.7 Ответ GigaChat2 Max на вопрос о цензуре

Исходя из ответа модели эти слова действительно являются причиной для блокировки запроса. Модель ограничивает ответы на запросы с содержанием данных тем.

Для получения рефератов были использованы следующие запросы:

Системный запрос: "Перескажи новостную статью в 25 - 50 слов"

Пользовательский запрос : "Статья:\n"

Доступ к использованию моделей YandexGPT5_PRO_RC и YandexGPT5_LITE_RC через API был получен с платформы Yandex Cloud. Время обработки 500 статей заняло 7 минут 15 секунд и 7 минут 49 секунд соответственно . У данной платформы нет ограничений на кол-во запросов в минуту, но есть пробный период с ограничением стоимости работы моделей в 5000 рублей. Но, что более важно, у данной платформы также достаточно чувствительная цензура к новостным статьям. Из 500 статей я получил рефераты лишь 231. То есть платформа заблокировала 269 запросов. При

отсутствии цензуры получение всех ответов заняло бы примерно 17 минут. Обработка 500 статей стоила 341 рубль и 54 рубля для моделей Pro и Lite. Ответ модели при цензуре не меняется : «В интернете есть много сайтов с информацией на эту тему. [Посмотрите, что нашлось в поиске](<https://ya.ru>)». При дальнейшем исследовании этого вопроса, выяснилось, что причина цензуры совпадает с моделью GigaChat, т.е слова политического содержания.

Рассмотрим таблицу 2.1, объединяющую всё вышесказанное в данном параграфе.

Таблица 2.1 - Объединение времени, стоимости, платформы моделей

Модель	Время обработки	Платформа для доступа	Кол-во полученных статей	Стоимость
IlyaGusev /rubert_ext_sum_gazeta	34 секунды	Модель из Hugging Face запущена в среде Google Colab с помощью GPU	500/500	Бесплатно Но доступ к GPU ограничен
IlyaGusev /rut5_base_sum_gazeta	9 минут 13 секунд		500/500	
IlyaGusev /rugpt3medium_sum_gazeta	27 минут		500/500	
GigaChat-2 (Lite)	4 минуты и 5 секунд ~ 11 минут для 500 статей	Доступ к API получен через платформу https://developers.sber.ru/ Код запущен в среде Google Colab	188/500	Бесплатно, но с ограничениями. Без ограничений: 40 рублей для 188 или 106 рублей для 500 статей
Yandex GPT 5 Pro	7 минут 49 секунд ~ 17 минут для 500 статей	Доступ к API получен через платформу	231/500	Бесплатно, но с ограничениями. Без ограничений: 341 рубль для 231 или 738 рублей для 500 статей

Yandex GPT 5 Lite	7 минут 15 секунд ~ 15 минут для 500 статей	Yandex Cloud. Код запущен в среде Google Colab	231/500	Бесплатно, но с ограничениями. Без ограничений: 54 рубля для 231 или 117 рублей для 500 статей
meta-llama/llama-4-scout-17b-16e-instruct	45 минут Скорость ограничена	Доступ к API получен через платформу Groq Cloud. Код запущен в среде Google Colab	500/500	Бесплатно, но с ограничениями. Без ограничений: 4 цента = 3,154 рубля
deepseek r1 distill llama 70b	1 час 11 минут Скорость ограничена		500/500	Бесплатно, но с ограничениями. Без ограничений: 50 центов = 41,5 рубля
Mistral 7B latest	50 минут Скорость ограничена	Доступ к API получен через платформу Mistral AI. Код запущен в среде Google Colab	500/500	Бесплатно, но с ограничениями. Без ограничений: неизвестно
Mistral Large latest	1 час 14 минут Скорость ограничена		500/500	

Из таблицы можно сделать следующие выводы:

– наиболее быстрая модель - IlyaGusev/rubert_ext_sum_gazeta, но причина такой скорости – это то, что модель является экстрактивной. Быстреейшей из абстрактивных моделей является IlyaGusev/rut5_base_sum_gazeta, а из LLM - GigaChat-2 (Lite). Стоит отметить, что для иностранных LLM в бесплатной версии ограничена скорость запросов в минуту, что сильно сказалось на результатах. Самая долгая модель - Mistral Large latest;

– самой дешёвой из LLM является llama-4-scout-17b-16e-instruct. Стоимость обработки 500 статей стоит всего 3 рубля. Наиболее дорогой(за исключением mistral, так как их стоимость неизвестна) является Yandex GPT 5 Pro с примерной стоимостью 738 рублей.

2.3. Оценка качества и анализ результатов

Для оценки качества рефератов для начала сравним длины рефератов моделей и журналистов (см. рис.2.8).

Сравнение распределений слов




Рисунок 2.8 - Сравнение распределения слов рефератов

Модели Yandex GPT5 и GigaChat были исключены из сравнения. Далее для каждой модели будут описаны совпадения и различия между распределением длин рефератов модели и журналистов:

1. ruBERT_ext_sum

- Форма распределения: асимметричное правостороннее, с выраженным «хвостом» в диапазоне 70–120 слов.
- Совпадение с оригиналом: медиана близка к 60 словам, схожая базовая форма гистограммы.
- Отличия: заметно больше примеров длинных резюме (70–120 слов), чем в исходных текстах.

2. ruT5_abs_sum

- Форма распределения: приблизительно симметричная «колоколообразная» кривая в диапазоне 30–60 слов.
- Совпадение с оригиналом: практически идентичные пики и «спады» на основных длинах (30, 40, 50 слов).
- Отличия: минимальны — одна из моделей с максимальным соответствием оригинальному распределению.

3. GPT_abs_sum

- Форма распределения: колоколообразная, но слегка смещена вправо к диапазону 50–70 слов.
- Совпадение с оригиналом: медиана около 55–60 слов против ~50 у оригинала; общая структура гистограммы схожа.
- Отличия: незначительное увеличение доли ответов длиной 65–80 слов.

4. meta-llama/llama-4-scout-17b-16e-instruct

- Форма распределения: очень узкая, с жёстко зафиксированным пиком около 50 слов. Наиболее вероятная причина такого пика – пользовательский и системный запросы, требующие реферат примерно в 45 слов.

- Совпадение с оригиналом: оригинал демонстрирует широкую вариативность (30–80 слов), тогда как модель выпускает тексты почти исключительно 45–55 слов.

- Отличия: крайне малая дисперсия — почти полностью отсутствуют короткие (<40) и длинные (>60) тексты.

5. deepseek-r1-distill-llama-70b

Форма распределения: узкая «колоколообразная» с диапазоном 40–65 слов. Несмотря на аналогичные запросы с моделью llama-4-scout-17b-16e-instruct, у данной модели нет такого явного пика около 45 слов.

- Совпадение с оригиналом: сходство в центральном диапазоне, но оригинал по-прежнему более разбросан.

- Отличия: ограниченное количество примеров за пределами 40–65 слов, что снижает вариативность.

6. mistral-8b-latest

- Форма распределения: заметно смещена вправо, с основным диапазоном 60–120 слов.

- Совпадение с оригиналом: у оригинала большинство текстов составляют 30–60 слов, здесь же масса генерируемых резюме длиннее 60 слов.

- Отличия: существенный сдвиг к более длинным ответам, почти полное отсутствие коротких текстов.

7. mistral-large-latest

- Форма распределения: правосторонняя, пик около 70 слов, диапазон 50–100 слов.

- Совпадение с оригиналом: медиана выше (≈ 70 против ≈ 50), но присутствуют и более короткие тексты.
- Отличия: четко выраженный сдвиг к более длинным формам и более густой «хвост» в длинном конце.

Ключевые выводы:

- Максимальное соответствие оригиналу демонстрирует модель ruT5_abs_sum.
- Наиболее узкие и «монодисперсные» распределения — у meta-llama и deepseek-r1.
- Наибольший сдвиг в сторону длинных резюме наблюдается у обеих моделей Mistral (8b и large).

Оценка качества текстов, сгенерированных моделью, сложна из-за множества способов получения сжатого текста. Даже если результат модели не идеально совпадает с эталоном (рефератом из набора данных), он может достаточно хорошо отражать суть (нередко из-за перефразирования или использования слов синонимов). Для оценки будем использовать метрики ROUGE-1, ROUGE-2, ROUGE-L, meteor, bleu.

Моделей Yandex GPT и GigaChat не будет в результатах, так как сравнение моделей на различных по объему выборках (например, 500 и 200 статей) может быть не вполне соразмерным с точки зрения метрик качества. Эти метрики являются агрегированными — они усредняются по всей выборке и чувствительны к размеру и разнообразию данных. При меньшем объеме выборки увеличивается дисперсия оценок, что может приводить к менее стабильным и менее репрезентативным результатам. Но если мы оцениваем качество работы данных моделей в задаче реферирования новостных статей, то мы можем сразу сказать, что оно неудовлетворительно из-за слишком чувствительной цензуры запросов. Данные модели могут не дать нам ответа

на половину запросов, что невозможно компенсировать даже при идеальном качестве рефератов.

Рассмотрим метрики рефератов моделей (см. рис.2.9).




Рисунок 2.9 - Сравнение метрик рефератов моделей

На представленной тепловой карте отражены значения метрик качества автоматического реферирования для семи моделей. Значения варьируются от наихудших (синие оттенки) до наилучших (красные оттенки).

Общие наблюдения:

1. Модели семейства LLaMA и Mistral демонстрируют наивысшее качество суммаризации. mistral-large-latest показывает наилучшие значения по ROUGE-1 (0.266), ROUGE-2 (0.083) и ROUGE-L (0.256), а также уверенно выступает по METEOR и BLEU. meta-llama/llama-4-scout-17b-16e-instruct находится на сопоставимом уровне, уступая лишь незначительно, преимущественно в метрике METEOR.

2. Модель gpt_abs_sum значительно уступает по всем метрикам. Она демонстрирует наименьшие значения ROUGE-1 (0.163), ROUGE-2

(0.022), ROUGE-L (0.158), METEOR (0.183) и BLEU (0.037), что свидетельствует о низкой способности генерировать информативные и лексически совпадающие с рефератами журналистов.

3. Модель `minstral-8b-latest` достигает лучшего результата по метрике METEOR (0.269), что может указывать на высокое качество перефразирования и лексического разнообразия, несмотря на немного более скромные показатели по ROUGE и BLEU.

4. Модели `rubert_ext_sum` и `rut5_abs_sum`, ориентированные на русский язык, показывают средние значения по всем метрикам. `rubert_ext_sum` особенно хорошо выступает по METEOR (0.267). `rut5_abs_sum` набрал лучшие результаты по метрике BLEU (0.09)

5. Модель `deepseek-r1-distill-llama-70b` демонстрирует стабильное, но не выдающееся качество, занимая промежуточную позицию между лучшими моделями и отстающими.

Наиболее высокие результаты демонстрируют модели на базе Mistral и LLaMA, особенно в версии `mistral-large-latest`, которая уверенно лидирует по большинству метрик. Это подтверждает высокий потенциал современных LLM в задаче автоматической суммаризации. Но стоит обратить внимание на то, что рефераты моделей mistral могут быть значительно длиннее, что может повлиять на результаты (в большую сторону), особенно на метрики ROUGE и METEOR. В то же время модели меньшего размера и специализированные на русском языке `rubert_ext_sum` и `rut5_abs_sum` показывают конкурентоспособное качество, что важно учитывать в условиях ограниченных вычислительных ресурсов или языковой специфики задачи. Наихудшей моделью по метрикам без сомнений является `gpt_abs_sum`.

ГЛАВА 3. РЕЗУЛЬТАТЫ И РЕКОМЕНДАЦИИ ПО ПРИМЕНЕНИЮ

3.1. Сравнение эффективности моделей в реферировании новостей

Для того, чтобы сделать окончательные выводы рассмотрим подробнее рефераты моделей для одного текста. Возьмём первый текст в датасете, для которого есть рефераты всех моделей. Для начала проанализируем метрики моделей для данного примера (см. рис.3.1).




Рисунок 3.1 - Метрики для одной пары

Анализ значений метрик будет ниже. Рассмотрим эталонный реферат(журналистов) и рефераты моделей (см. рис.3.2).

РЕФЕРАТ ЖУРНАЛИСТОВ

Руководство Ford в очередной раз сделало выпад в сторону Tesla. На этот раз генеральный директор автопроизводителя заявил о том, компания Илона Маска заставляет покупателей самостоятельно «обкатывать» новую технологию автопилота, чего не позволяет себе Ford. По словам экспертов, конфликт между автопроизводителями связан с угрозами для классического автопрома, которые может принести Tesla.

Рис. 3.2 Реферат журналистов

Реферат rubert_ext_sum

Генеральный директор Ford Джим Фарли обвиняет Tesla в использовании своих клиентов для тестирования недоработанных технологий, сообщает портал CNBC. Несмотря на свое название, система не может самостоятельно управлять электрокаром. Стоит отметить, что руководство Ford далеко не единожды делало выпады в сторону Tesla.

Анализ:

- Длина: Примерно соответствует эталону.
- Добавленные детали: Источник (CNBC), упоминание неполной автономности.
- Важность деталей: Указание источника - не самая суть. Неполная автономность - уместно, но не критично для краткого реферата.
- Недостатки: Все еще отсутствует ключевая информация из эталона: контр-аргумент Ford (что они так не делают / их система) и мнение экспертов о причинах.
- Вердикт: Соблюдает длину, но упускает важные части оригинала. Добавления не компенсируют упущения.

– Интерпретация метрик (ROUGE1: 0.889, ROUGE2: 0.571, ROUGEL: 0.889, METEOR: 0.249, BLEU: 0.057): Очень высокие ROUGE-1/L объясняются тем, что та часть, которую реферат освещает (обвинение Ford), сформулирована очень близко к эталону. Метрики показывают высокую степень лексического совпадения по этой части. Однако они не отражают полноту освещения всех аспектов эталона.

Реферат rut5_abs_sum

Генеральный директор Ford Джим Фарли обвинил Tesla в использовании своих клиентов для тестирования недоработанных технологий. По его словам, компания Илона Маска выпустила бета-версию своего автопилота в октябре прошлого года, но отозвала доступ для некоторых из них, так как те не обращали внимания на дорогу.

Анализ:

- Длина: Примерно соответствует эталону.
- Добавленные детали: Детали про бета-версию и отзыв доступа.
- Важность деталей: Уточнение про "бета-версию" полезно. Отзыв доступа - второстепенная деталь для краткого реферата.
- Недостатки: Все еще отсутствует позиция Ford и мнение экспертов.
- Вердикт: Соблюдает длину, добавляет полезное уточнение (бета), но все еще не полон по сравнению с эталоном.

– Интерпретация метрик (ROUGE1: 0.667, ROUGE2: 0.5, ROUGEL: 0.667, METEOR: 0.257, BLEU: 0.062): Умеренные ROUGE и наивысший METEOR (0.257) предполагают неплохое совпадение по ключевым словам и синонимам с той частью эталона, которую он покрывает. Опять же, неполнота не так сильно штрафует, если совпадающая часть хорошо передана.

Реферат gpt_abs_sum

Генеральный директор Tesla Джим Фарли обвинил компанию Илона Маска в том, что она использует своих клиентов, чтобы тестировать недоработанные

технологии. По его словам, Tesla тестировала свой автопилот в реальном мире и не обращала внимания на дорогу, что привело к авариям.

Анализ:

- Длина: Примерно соответствует эталону.
- Добавленные детали: Упоминание аварий из-за невнимательности.
- Важность деталей: Контекстуально релевантно, но не заменяет основную мысль.
- Недостатки: Критическая ошибка (CEO Tesla), отсутствует позиция Ford и мнение экспертов.
- Вердикт: Непригоден из-за ошибки, независимо от длины.
- Интерпретация метрик (ROUGE1: 0.667, ROUGE2: 0.0, ROUGEL: 0.667, METEOR: 0.248, BLEU: 0.0): ROUGE-2 и BLEU равные нулю хорошо коррелируют с непригодностью реферата. Это указывает на отсутствие совпадающих пар слов и более длинных фраз с (предположительно корректным) эталоном, использованным для расчета метрик.

Реферат YandexGPT5_PRO_RC

Генеральный директор Ford Джим Фарли обвинил Tesla в использовании клиентов для тестирования недоработанной системы автопилота FSD. Он анонсировал запуск собственной системы BlueCruise, которая, по его словам, уже протестирована. Эксперты считают, что Ford пытается подмочить репутацию Tesla, но спрос на автомобили компании Маска растёт. Tesla, в свою очередь, открыто говорит о том, что её система не полностью автономна и обновляется благодаря пользователям.

Анализ:

- Длина: Заметно длиннее эталона (~70 слов).
- Добавленные детали: Названия FSD/BlueCruise, заявление Ford "протестирована", позиция Tesla.

- Важность деталей: Названия систем (FSD/BlueCruise) и заявление Ford о тестировании - очень важные детали, добавляющие конкретику и полноту картине конфликта. Позиция Tesla добавляет баланса.
- Недостатки: Превышает желаемую длину.
- Вердикт: Содержательно превосходит эталон, добавляя важные детали, но не соответствует ограничению по длине.
- Интерпретация метрик (ROUGE1: 0.727, ROUGE2: 0.444, ROUGEL: 0.727, METEOR: 0.244, BLEU: 0.0): Хорошие ROUGE-1/L отражают включение многих ключевых элементов из нового эталона. Умеренный ROUGE-2 также закономерен. BLEU=0 по-прежнему указывает на разницу в структуре предложений.

Реферат YandexGPT5_Lite_RC

Генеральный директор Ford Джим Фарли обвинил Tesla в использовании клиентов для тестирования недоработанных технологий автопилота. Ford запустил собственную систему автопилота BlueCruise, протестированную в реальном мире, чтобы избежать подобных практик. Эксперты считают, что Tesla честно информирует покупателей о статусе своих технологий, в то время как Ford пытается подмочить репутацию конкурента. Ford видит угрозу в Tesla и пока не решается открыто бросить ей вызов.

Анализ:

- Длина: Немного длиннее эталона (~65 слов).
- Добавленные детали: Название BlueCruise, заявление Ford "протестирована", интерпретация мнения экспертов.
- Важность деталей: BlueCruise и заявление Ford - важные добавления. Интерпретация экспертов - добавляет нюанс, но увеличивает объем.
- Недостатки: Слегка превышает длину.
- Вердикт: Хороший баланс: близок к нужной длине, включает важные добавления (BlueCruise), хотя и чуть длиннее.

– Интерпретация метрик (ROUGE1: 0.667, ROUGE2: 0.6, ROUGEL: 0.667, METEOR: 0.19, BLEU: 0.0): Высокий ROUGE-2 (0.6) очень показателен. Это может означать, что реферат хорошо уловил ключевые фразы из эталона, касающиеся действий Ford и его контр-позиции. Умеренные ROUGE-1/L это подтверждают.

Реферат GigaChat_2_Lite

Гендиректор Ford Джим Фарли раскритиковал Tesla за использование бета-версии автопилота без устранения ошибок, назвав это рискованным подходом к безопасности. В ответ Tesla утверждает, что водители сами решают, насколько готовы пользоваться системой. Руководители обеих компаний неоднократно обменивались выпадами, подчеркивая разницу в подходе к технологиям автономного вождения.

Анализ:

– Длина: Примерно соответствует эталону.
– Добавленные детали: Ответный аргумент Tesla (выбор водителя), уточнение критики (бета без исправлений).

– Важность деталей: Аргумент Tesla - важное добавление для баланса. Уточнение критики - полезно.

– Недостатки: Все еще отсутствует позиция Ford о своей системе и мнение экспертов о причинах конфликта.

– Вердикт: Соблюдает длину, добавляет важный контраргумент Tesla, но упускает другие ключевые части эталона.

– Интерпретация метрик (ROUGE1: 0.857, ROUGE2: 0.4, ROUGEL: 0.857, METEOR: 0.111, BLEU: 0.0): Высокие ROUGE-1/L вновь указывают на точное воспроизведение той части информации, которая совпадает с эталоном (критика Ford в адрес Tesla). Однако очень низкий METEOR и BLEU, а также качественный анализ показывают, что общая картина далека от эталона.

Реферат meta-llama/llama-4-scout-17b-16e-instruct

Глава Ford Джим Фарли обвинил Tesla в том, что компания использует своих клиентов для тестирования недоработанных технологий. Фарли анонсировал запуск системы автопилота BlueCruise, которая уже была протестирована в реальных условиях. Таким образом, он намекнул на бета-версию автопилота Tesla. Эксперты считают, что Ford пытается undermine репутацию Tesla.

Анализ:

- Длина: Примерно соответствует эталону.
- Добавленные детали: Название BlueCruise, заявление Ford "протестирована".
- Важность деталей: BlueCruise и заявление Ford - очень важные детали, напрямую относящиеся к сути конфликта и контраргументу Ford.
- Недостатки: Использование слова "undermine".
- Вердикт: Отлично соблюдает длину и добавляет критически важные детали, которых не было в эталоне, но которые нужны для полноты. Один из лучших по балансу длины и содержания.
- Интерпретация метрик (ROUGE1: 0.727, ROUGE2: 0.444, ROUGEL: 0.727, METEOR: 0.2, BLEU: 0.0): Хорошие ROUGE и METEOR подтверждают качественную оценку. Этот реферат демонстрирует хороший баланс между полнотой (согласно эталону) и метриками сходства.

Реферат deepseek-r1-distill-llama-70b

Генеральный директор Ford Джим Фарли обвинил Tesla в использовании клиентов для тестирования недоработанного автопилота FSD. В ответ Ford представила уже протестированную систему BlueCruise. Tesla ранее выпустила бета-версию FSD, которая вызвала критику из-за неполной автономности и аварий. Эксперты считают, что Ford пытается подорвать репутацию Tesla, но конкуренция на рынке электромобилей остаётся напряжённой.

Анализ:

- Длина: Немного длиннее эталона (~60 слов).

- Добавленные детали: Названия FSD/BlueCruise, заявление Ford "протестирована", упоминание критики/аварий Tesla.
- Важность деталей: Названия систем и заявление Ford - важные. Упоминание критики/аварий - релевантный контекст.
- Недостатки: Слегка превышает длину.
- Вердикт: Очень содержательный, добавляет важные детали, но немного выходит за рамки длины.
- Интерпретация метрик (ROUGE1: 0.615, ROUGE2: 0.364, ROUGEL: 0.615, METEOR: 0.168, BLEU: 0.0): Удивительно, но метрики здесь ниже, чем у некоторых других сопоставимых по качеству рефератов (например, llama-4-scout). Это подчеркивает, что даже семантически близкий реферат может получить не самые высокие оценки, если его формулировки и структура отличаются от эталона.

Реферат ministrall-8b-latest

Генеральный директор Ford Джим Фарли обвинил Tesla в использовании клиентов для тестирования недоработанных технологий. Он объявил о запуске собственной системы автопилота, подчеркнув, что Ford уже протестировала её в реальных условиях. Фарли также упомянул, что Tesla выпустила бета-версию автопилота, которая не полностью автономна. В 2020 году Ford критиковала Tesla за некачественную сборку, а в 2018 году — за производительность. Эксперты считают, что Ford пытается подорвать репутацию Tesla, но покупатели продолжают выбирать Tesla.

Анализ:

- Длина: Заметно длиннее эталона (~80 слов).
- Добавленные детали: BlueCruise, заявление Ford "протестирована", детали бета-версии, исторический контекст, нюансы мнения экспертов.
- Важность деталей: BlueCruise и заявление Ford - важные. Исторический контекст - интересно, но не обязательно для краткого реферата о текущем событии и сильно увеличивает длину.

- Недостатки: Значительно превышает желаемую длину из-за добавления не самой критичной информации (история).
- Вердикт: Слишком длинный для задачи, хотя и содержит важные детали среди прочих.
- Интерпретация метрик (ROUGE1: 0.533, ROUGE2: 0.462, ROUGEL: 0.533, METEOR: 0.199, BLEU: 0.0): Умеренные ROUGE отражают тот факт, что из-за большого количества дополнительной информации степень прямого лексического пересечения с кратким эталоном снижается.

Реферат mistral-large-latest

Генеральный директор Ford Джим Фарли критикует Tesla за использование клиентов для тестирования недоработанных технологий автопилота. Ford запускает свою систему BlueCruise, утверждая, что она уже протестирована. Tesla выпустила бета-версию своего автопилота, что вызвало критику и расследования из-за аварий. Эксперты считают, что Ford пытается подмочить репутацию Tesla, но признают успех и рост спроса на электромобили Tesla.

Анализ:

- Длина: Длиннее эталона (~70 слов).
- Добавленные детали: BlueCruise, заявление Ford "протестирована", детали бета-версии, упоминание расследований/аварий, нюансы мнения экспертов.
- Важность деталей: BlueCruise и заявление Ford - важные. Упоминание расследований/аварий - важный контекст риска.
- Недостатки: Превышает желаемую длину.
- Вердикт: Содержательный, добавляет важные детали и контекст (расследования), но длиннее требуемого.
- Интерпретация метрик (ROUGE1: 0.667, ROUGE2: 0.6, ROUGEL: 0.667, METEOR: 0.197, BLEU: 0.0): Хорошие ROUGE-1/L и высокий ROUGE-2 (0.6) подтверждают, что реферат хорошо передает основные

информационные блоки из эталона журналистов, особенно обвинение и контр-позицию Ford.

Выводы касательно данных рефератов:

- Лучший баланс длины и содержания: meta-llama отлично справился, оставшись в рамках длины и добавив ключевые детали (BlueCruise, "протестировано"). YandexGPT5_Lite_RC и deepseek-r1-distill-llama-70b тоже хороши, не сильно выходя за рамки длины и добавляя важную информацию.
- Содержательные, но длинные: YandexGPT5_PRO_RC и mistral-large-latest добавили очень важные детали, но превысили объем. ministral-8b-latest тоже содержателен, но его длина увеличена за счет менее критичного исторического контекста.
- Соблюдают длину, но неполные: rubert_ext_sum, rut5_abs_sum, GigaChat_2_Lite остались краткими, но упустили важные элементы из исходного реферата журналистов (позицию Ford или мнение экспертов).
- Ошибочный: gpt_abs_sum остается непригодным.

Выводы, касающиеся результатов анализа моделей, представлены в таблице 3.1.

Таблица 3.1 - Результаты анализа рефератов моделей

Модель	Длина рефератов	Достоинства	Недостатки	Метрики
rubert_ext_sum	Немного длиннее. Есть рефераты > 100 слов	Малый размер модели, высокая скорость обработки.	Упускает важные части оригинала. Не может связать реферат в один текст, так как просто выделяет наиболее значимые предложения.	Высокое значение METEOR
rut5_abs_sum	Почти соответствует	Малый размер модели, высокая скорость обработки.	Упускает важные части оригинала, добавляет лишние.	Наивысшее значение BLEU

gpt_abs_sum	Немного короче	Малый размер модели, высокая скорость обработки.	Непригоден из-за критической ошибки, «галлюцинации» в реферате	Худшая модель по всем метрикам
Yandex GPT5_PRO_RC	Длиннее эталона	Добавляет важные детали.	Непригодна из-за цензурирования	нет результатов
Yandex GPT5_Lite_RC	Немного длиннее эталона	Добавляет важные детали. Относительно малый размер по сравнению с другими LLM	Непригодна из-за цензурирования	нет результатов
GigaChat_2_Lite	Примерно соответствует эталону.	Добавляет важные детали.	Непригодна из-за цензурирования	нет результатов
meta-llama/llama-4-scout-17b-16e-instruct	Примерно соответствует эталону. Значительно больше рефератов около 45 слов. Нет рефератов < 30 слов	Добавляет важные детали, Одна из лучших моделей по балансу длины и содержания.	Использование излишних иностранных слов	Высокие ROUGE 1, L. Выше среднего остальные метрики
deepseek-r1-distill-llama-70b	Примерно соответствует эталону. больше рефератов около 45 - 60 слов. Нет рефератов < 30 слов	Очень содержательные рефераты. Добавляет важные детали.	Большой размер модели, большие вычислительные затраты на обработку.	Высокие ROUGE 1, L.
ministral-8b-latest	Значительно длиннее. Основной диапазон 60–120 слов.	Добавляет важные детали. Относительно малый размер по сравнению с другими LLM	Добавляет не только важные детали, но и излишнюю информацию. Значительно превышает длину эталонов	Наивысшее значение METEOR. Высокий ROUGE 2 Плохой BLEU

mistral-large-latest	Длиннее. Основной диапазон 50–100 слов.	Содержательный. Добавляет важные детали	Превышает желаемую/запрашиваемую длину.	Наивысшее значение ROUGE 1, 2, L Плохой BLEU
----------------------	---	---	---	---

Исходя из всех факторов выделяются следующие модели:

- rut5_abs_sum своим размером, скоростью, соответствием длины с рефератами журналистов.
- meta-llama/llama-4-scout-17b-16e-instruct балансом длины и содержания, качеством ответов, высокими метриками.
- mistral-large-latest наивысшим значением ROUGE 1, 2, L

Говоря о модели mistral-large-latest, стоит сказать, что высокое значение метрик может быть обусловлено не качеством рефератов, а их длиной. Исследования показывают, что многие автоматические метрики оценки реферирования могут иметь склонность отдавать предпочтение более длинным сгенерированным рефератам, даже если они не всегда лучшего качества с точки зрения человеческой оценки. Это связано с тем, что большая длина увеличивает вероятность случайных совпадений с референсом, особенно для метрик, сильно зависящих от полноты. Ответы данной модели можно назвать плохими, если перед вами стоит задача реферирования со строгими рамками для рефератов.

Модель rut5_abs_sum

Для кого и для каких случаев предпочтительна:

- Пользователи и организации с ограниченными вычислительными ресурсами: Благодаря своему меньшему размеру, rut5_abs_sum менее требовательна к аппаратному обеспечению. Это делает её доступной для тех, у кого нет возможности использовать дорогие GPU или облачные вычисления для каждой задачи.

- Задачи автоматического создания первичных аннотаций на русском языке: Если вам нужно быстро получить краткое содержание большого количества русскоязычных документов (например, новостных статей, отчетов, научных публикаций) и приемлемо среднее качество с возможностью последующей доработки, эта модель подойдет.

- Встраиваемые системы или приложения с быстрой реакцией: Меньший размер модели способствует более быстрому времени отклика, что может быть критично для некоторых приложений.

Особенности:

- Экономичность и доступность: Основное преимущество – низкие требования к ресурсам.

- Специализация на русском языке и реферировании: Модель настроена на конкретную задачу и язык, что может давать приемлемые результаты именно в этой нише без необходимости сложных настроек.

- Недостатки: Качество рефератов может быть не всегда высоким и иногда требует проверки или коррекции. Модель менее гибка для других языковых задач.

Модель `meta-llama/llama-4-scout-17b-16e-instruct`

Для кого и для каких случаев предпочтительна:

- Исследователи и разработчики, работающие над сложными NLP-задачами: Если требуется высочайшее качество генерации текста, глубокое понимание контекста и точное выполнение детализированных инструкций (например, написание кода по описанию, создание аналитических отчетов, генерация креативного контента по сложным запросам).

- Компании, разрабатывающие продвинутых чат-ботов и виртуальных ассистентов: Способность строго следовать инструкциям и генерировать качественные, осмысленные ответы делает её отличным выбором для создания сложных диалоговых систем.

- Задачи, требующие высокой степени кастомизации и контроля над результатом: Формулируя точные инструкции, можно гибко управлять выводом модели для широкого спектра применений, от переводов и реферирования до ответов на специфические вопросы.

Особенности:

- Высокое качество и следование инструкциям: Модель способна генерировать текст высокого качества и точно выполнять поставленные задачи, если они четко сформулированы.

- Широкая эрудиция и многозадачность: Большой размер и объем обучающих данных позволяют модели справляться с разнообразными и сложными языковыми задачами, выходящими далеко за рамки простого реферирования.

- Недостатки: Требуется значительных вычислительных ресурсов, что делает её дорогой и сложной в развертывании для многих пользователей.

3.2. Рекомендации по применению моделей в реальной практике

Из анализа рефератов моделей из параграфов 2.3 и 3.1 следует выбор 2 лучших моделей для реферирования новостных статей:

- `rut5_abs_sum` - экономичный инструмент для автоматического реферирования русскоязычных текстов, компромисс в качестве ради доступности и скорости на менее мощном оборудовании. Но, данную модель придётся дообучать для конкретно вашей задачи.
- `meta-llama/llama-4-scout-17b-16e-instruct` обеспечивает максимальное качество, гибкость и точное следование инструкциям для выполнения разнообразных и сложных языковых задач, но требует больших вычислительных мощностей.

Модель `rut5_abs_sum` идеально подходит для сценариев, где ключевыми факторами являются стоимость развертывания, скорость обработки и ресурсоэффективность, даже ценой некоторого компромисса в качестве по сравнению с более крупными моделями.

Модель может использоваться в следующих областях:

- Новостные агрегаторы: `rut5_abs_sum` может быстро создавать краткие аннотации для большого количества русскоязычных новостных статей, позволяя пользователям быстро ознакомиться с содержанием без необходимости открывать каждую статью целиком. Его экономичность делает его масштабируемым решением для обработки больших потоков новостей.
- Боты в мессенджерах: Может использоваться для предоставления кратких сводок статей или сообщений по запросу пользователя в русскоязычных чатах. Его низкие требования к ресурсам позволяют развертывать его даже на ограниченных платформах.
- Внутренние корпоративные инструменты: Для быстрого реферирования внутренних документов, отчетов или переписки на русском

языке, где нет необходимости в идеальном качестве, но важна скорость и доступность на стандартном офисном оборудовании.

Модель llama-4-scout-17b-16e-instruct – это мощная, гибкая и точная модель, требующая значительных вычислительных ресурсов. Она лучше всего проявляет себя в задачах, где приоритетом является высокое качество результата, глубокое понимание контекста, способность следовать сложным инструкциям и обрабатывать различные типы данных (включая мультимодальные). Например:

- ИИ-помощники: Идеально подходит для создания многофункциональных ИИ-помощников, способных вести диалог на различные темы, понимать сложные запросы, генерировать креативный контент, работать с изображениями и следовать детальным инструкциям пользователя. Это могут быть виртуальные ассистенты для бизнеса, образования или персонального использования.

- Поисковые системы (для улучшения результатов): Может использоваться для улучшения понимания запросов пользователей, генерации более релевантных сниппетов (кратких описаний страниц в результатах поиска), суммаризации содержимого веб-страниц для быстрого предпросмотра, или даже для реализации функций ответов на вопросы на основе найденной информации.

- Системы анализа и обработки больших данных: Благодаря большому контекстному окну и возможности обработки сложных запросов, модель может применяться для анализа объемных текстовых данных, извлечения ключевой информации, суммаризации длинных документов (например, юридических или научных), а также для задач, требующих комплексного рассуждения.

Какую и где лучше использовать:

- Для новостных агрегаторов и простых ботов в мессенджерах, где нужна быстрая и экономичная суммаризация русскоязычных текстов на

массовом потоке данных без высоких требований к идеальному качеству, rut5_abs_sum будет предпочтительнее

– Для создания продвинутых ИИ-помощников, интеграции в поисковые системы для глубокого анализа и генерации качественных ответов, а также в любых сценариях, требующих обработки сложных запросов, мультимодальности, точного следования инструкциям и максимального качества результатов при наличии необходимых вычислительных ресурсов, выбор однозначно падает на meta-llama/llama-4-scout-17b-16e-instruct.

Таким образом, выбор между моделями полностью зависит от специфики задачи, доступных вычислительных ресурсов и приоритетов проекта (скорость и экономичность против максимального качества и многофункциональности).

3.3. Возможности улучшения моделей и перспективы развития

Рассмотрим подробнее как можно было бы улучшить результаты модели `rut5_base_sum_gazeta`. Наиболее важное изменение, которое могло бы улучшить качество рефератов на этапе использования модели – это стратегия декодирования. Текущая стратегия – это Greedy Search с ограничением на повторение 4-грамм (`no_repeat_ngram_size=4`), то есть модель не сможет сгенерировать последовательность из 4 слов, которая уже встречалась в сгенерированном тексте. Это помогает бороться с проблемой частых повторов, которые могут возникать при использовании простых стратегий декодирования. Существует несколько стратегий:

Greedy Search (Жадный поиск): самый простой метод, выбирает наиболее вероятное слово на каждом шаге. Часто приводит к повторяющимся и не очень качественным результатам.

Beam Search (Лучевой поиск): исследует несколько наиболее вероятных последовательностей слов (`num_beams`). Обычно дает более связные и качественные результаты. Можно настроить:

- `length_penalty`: штраф за длину. Значения > 1.0 поощряют более длинные последовательности, < 1.0 — более короткие;
- `no_repeat_ngram_size`: запрещает повторение n-грамм, помогает избежать заикливания.

Sampling (Сэмплирование): вносит случайность в процесс генерации.

- Top-k sampling: на каждом шаге выбирается слово из k наиболее вероятных;
- Nucleus sampling (Top-p sampling): выбирается из минимального набора слов, чья суммарная вероятность превышает порог p;
- temperature: контролирует случайность. Более высокие значения (например, 0.8-1.0) делают вывод более случайным и творческим, низкие (например, 0.2-0.5) — более детерминированным и сфокусированным.

Для того, чтобы данная модель демонстрировала хорошие/средние результаты не только на статьях издательства газета.RU, но и в других областях, необходимо будет дообучить модель на датасете для вашей задачи. Если у вас уже имеется датасет с парами : [текст, реферат], то вы можете дообучить модель используя классы `Trainer`, `TrainingArguments` из библиотеки `transformers` (см. рис.3.3).

```
from transformers import Trainer, TrainingArguments

training_args = TrainingArguments(
    output_dir="./results_new_domain",
    evaluation_strategy="epoch",
    learning_rate=3e-5,
    per_device_train_batch_size=4, # подберите под вашу GPU
    per_device_eval_batch_size=4, # подберите под вашу GPU
    num_train_epochs=3,
    weight_decay=0.01,
    save_total_limit=3, # сохранять несколько лучших чекпоинтов
    predict_with_generate=True, # необходимо для метрик реферирования
    # ... другие параметры
)

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=tokenized_train_dataset, # ваши токенизированные данные
    eval_dataset=tokenized_val_dataset,   # ваши токенизированные данные
    tokenizer=tokenizer,
    # data_collator=... # если нужен специальный сборщик батчей
    # compute_metrics=compute_rouge_metrics # функция для подсчета ROUGE
)

trainer.train()
```

Рисунок 3.3 Пример кода для дообучения моделей

Кроме полного дообучения всех весов модели, можно заморозить все веса, кроме весов последних слоёв. Это поможет ускорить дообучение и уменьшит вычислительные затраты. Также методы, такие как LoRA (Low-Rank Adaptation), позволяют дообучать модель с гораздо меньшим количеством обновляемых параметров. Это экономит ресурсы и может помочь предотвратить катастрофическое забывание. Hugging Face библиотека `peft` поддерживает такие методы

Также есть множество методов, направленных на улучшение работы LLM. Качество ответа LLM напрямую зависит от качества запроса (промпта). Для улучшения ответов стоит обратить внимание на:

- Четкость и конкретность: избегать двусмысленности. Чем точнее и детальнее сформулирован запрос, тем лучше LLM поймет, что от нее требуется.

- Задание роли (Role Prompting): попросите LLM вести себя как определенный эксперт или персонаж. Например: "Представь, что ты опытный маркетолог. Предложи три креативные идеи для продвижения нового экологичного продукта."

- Предоставление контекста: включите в запрос релевантную информацию, которая поможет LLM дать более точный и полезный ответ. Если вы задаете вопрос о сложном термине, укажите область знаний, к которой он относится.

Более продвинутые методы предлагают использовать:

- Few-Shot Learning (Обучение на нескольких примерах) для Реферирования. Надо предоставить LLM несколько примеров пар "исходный текст – идеальный реферат". Это особенно полезно, если вам нужен реферат в специфическом стиле, с определенным уровнем детализации или с акцентом на конкретные аспекты.

Пример запроса:

«Текст 1: [Длинный отрывок о влиянии изменения климата на сельское хозяйство]

Реферат 1: [Краткий, точный реферат, подчеркивающий экономические последствия]

Текст 2: [Другой длинный отрывок о методах адаптации сельского хозяйства к изменению климата]

Реферат 2: [Краткий, точный реферат, фокусирующийся на предлагаемых решениях]

Текст 3: [Ваш текст для реферирования]

Реферат 3:»

– Chain-of-Thought Prompting (CoT). Надо попросить LLM сначала выполнить промежуточные шаги перед созданием финального реферата. Это может значительно улучшить логику и полноту реферата.

Пример запроса:

Текст: [Ваш текст]

Инструкция: "Проанализируй следующий текст. Сначала выдели 3-5 ключевых идей или аргументов этого текста. Затем, на основе этих ключевых идей, напиши связный реферат объемом не более 100 слов."

Вариация:

Можно попросить сначала составить экстрактивный реферат (ключевые предложения из текста), а затем на его основе создать абстрактный (перефразированный) реферат.

– Self-Consistency (Самосогласованность) для повышения надежности реферата: Попросить модель сгенерировать несколько вариантов реферата для одного и того же текста (например, используя параметр "температура" для вариативности). Затем выбрать лучший вариант на основе метрик или разработать критерии для автоматического отбора (например, по покрытию ключевых слов, отсутствию противоречий).

– Контроль параметров генерации. При обращении к LLM через API часто можно указать дополнительные параметры, такие как:

Temperature (Температура): Для рефератов обычно предпочтительны низкие значения (0.1-0.4) для большей точности, предсказуемости и следования исходному тексту. Более высокие значения могут привести к излишней "креативности" и отходу от сути.

Max Tokens (Максимальное количество токенов): Критически важный параметр для контроля длины реферата. Устанавливайте его в соответствии с вашими требованиями.

Top-p (Nucleus Sampling): Альтернатива температуре для контроля предсказуемости.

Presence Penalty / Frequency Penalty: Могут помочь избежать ненужных повторов слов или фраз в реферате, делая его более лаконичным.

Также для улучшения качества ответов своих LLM Mistral AI разработала комплексную платформу La Plateforme. Одним из ключевых аспектов La Plateforme является предоставление средств для кастомизации моделей, включая эффективное дообучение с использованием метода LoRA. Для упрощения процесса дообучения Mistral AI предлагает мощный и удобный Fine-Tuning API. Этот API позволяет пользователям дообучать модели Mistral AI без необходимости развертывания и управления собственной дорогостоящей инфраструктурой GPU. Он поддерживает как открытые, так и коммерческие модели, абстрагируя сложность низкоуровневых деталей и предоставляя готовые к использованию программные интерфейсы (endpoints). Такой подход значительно экономит время и снижает вероятность ошибок, связанных с настройкой окружения и конфигурации.

Помимо облачного API, Mistral AI также предоставляет open-source библиотеку mistral-finetune. Эта библиотека представляет собой легкую и эффективную кодовую базу, специально разработанную для дообучения моделей Mistral AI на локальной или частной инфраструктуре пользователя. В основе mistral-finetune лежит парадигма обучения LoRA, что обеспечивает высокую производительность при минимальном потреблении памяти. Библиотека поддерживает все открытые модели, разработанные Mistral AI, предоставляя большую гибкость и контроль над процессом дообучения для опытных пользователей. (см. рис. 3.4)




Рисунок 3.4 - Интерфейс обучения на La Plateforme

Как можно увидеть из рисунка на платформе можно управлять скоростью обучения, количеством эпох для обучения, выбрать обучаемую модель и добавить датасет для обучения в формате json.

ЗАКЛЮЧЕНИЕ

В ходе работы:

- найден и подробно проанализирован датасет с новостными статьями издательства газета.RU;
- проведена генерация рефератов 10 моделями для 500 новостных статей;
- проведён сравнительный анализ рефератов десяти трансформенных моделей, решающих задачу автоматического реферирования текстов. В результате анализа были выявлены 2 лучшие модели : rut5_abs_sum и llama-4-scout-17b-16e-instruct. В частности, rut5_abs_sum – наиболее экономичная модель, которая может быть запущена на слабом оборудовании для получения средних по качеству рефератов. Но модель узкоспециализирована и её придётся дообучать для использования в других областях. Модель llama-4-scout же обеспечивает высокое качество рефератов, чёткое следование инструкциям и способна решать большой спектр задач при доступе к значительным вычислительным ресурсам;
- предложены области для применения моделей. Модель rut5_abs_sum может использоваться в новостных агрегаторах, ботах и мессенджерах, внутренних корпоративных инструментах. Модель llama-4-scout-17b-16e-instruct может использоваться в ИИ-помощниках, поисковых системах, системах анализа и обработки больших данных;
- предложены рекомендации по улучшению модели rut5_abs_sum и её дообучению для других задач. А именно: изменить стратегию декодирования(с жадного поиска на лучевой или сэмплирование) или дообучить модель используя библиотеку transformers, заморозить веса и дообучить лишь последние слои или же использовать LoRA;
- предложены рекомендации по улучшению работы всех LLM. Например: детальнее сформулировать запрос, задать роль, использовать

обучение на нескольких примерах, попросить LLM сначала выполнить промежуточные шаги перед созданием финального реферата, попросить модель сгенерировать несколько вариантов реферата и выбрать лучший, изменить параметры генерации;

– предложен способ для улучшения ответов моделей Mistral. А именно использовать платформу Mistral AI или библиотеку mistral-finetune для дообучения моделей используя LoRA.

Данная работа выполнена мною самостоятельно
«31» мая 2025г.



СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Браславский, П. И., Густелев, В. Система автоматического реферирования новостных сообщений на основе машинного обучения [Текст] / П. И. Браславский, В. Густелев // Тр. IX Всерос. науч. конф. RCDL 2007. – Переславль-Залесский : Изд-во ун-та, 2007. – С. 142–147.
2. Кондратьев, М. Аннотирование по запросу: связность или информативность / М. Кондратьев // Труды третьего российского семинара по оценке методов информационного поиска / под ред. И.С. Некрестьянова. – СПб.: НИИ Химии СПбГУ, 2005. – С. 125–135.
3. Лахути, Д. Г., Блюменау, Д. И., Гендина, Н. И. Формализованное реферирование с использованием словесных клише (маркеров) [Текст] / Д. Г. Лахути, Д. И. Блюменау, Н. И. Гендина // НТИ. – 1981. – Сер. 2. – № 2. – С. 16–20.
4. Севбо, И.П. Структура связного текста и автоматизация реферирования: Монография [Текст]/ И.П. Севбо.-М.: Наука, 1969.-135 с.
5. Хан, У., Мани, И. Системы автоматического реферирования [Текст] / У. Хан, И. Мани // Открытые системы. – 2000. – № 12 (<http://www.osp.ru/os/2000/12/067.htm>).
6. Автоматическое реферирование текстов. Обзор работ. [Электронный ресурс]. - Режим доступа: https://habr.com/ru/companies/unistar_digital/articles/684830/ (дата обращения: 01.12.2024).
7. Методы автоматического реферирования. [Электронный ресурс]. - Режим доступа: <https://studfile.net/preview/9243307/page:6/> (дата обращения: 01.12.2024).
8. Современные методы автоматического реферирования. [Электронный ресурс]. - Режим доступа: <https://cyberleninka.ru/article/n/sovremennyye-metody-avtomaticheskogo-referirovaniya> (дата обращения: 01.12.2024).

9. Edmundson, H. P. New Methods in Automatic Extracting [Текст] / H. P. Edmundson // Journal of the Association for Computing Machinery. – Apr. 1969. – № 16(2). – P. 264–285.
10. Hirao, T., Isozaki, H., Maeda, E. et al. Extracting Important Sentences with Support Vector Machines [Текст] / T. Hirao, H. Isozaki, E. Maeda et al. // In Proc. of the 19 International Conf. on Computational Linguistics. – 2002. – Vol. 1. – P. 1–7.
11. Hovy, E., Lin, C-Y. Automated Text Summarization in SUMMARIST / E. Hovy, C-Y. Lin // Advances in Automatic Text Summarization / M.T. Maybury (ed.). – The MIT Press, 1999. – P. 81–94.
12. Liu, Y., Lapata, M. Text Summarization with Pretrained Encoders // arXiv.org. – 2019. – URL: <https://arxiv.org/abs/1908.08345> (дата обращения: 01.12.2024).
13. Liu, P.J., Saleh, M., Pot, E., Goodrich, B., Sepassi, R., Kaiser, L., Shazeer, N.M. Generating Wikipedia by Summarizing Long Sequences // International Conference on Learning Representations (ICLR). – 2018.
14. McKeown, K.R., Robin, J., Kukich, K. Generating concise natural language summaries [Текст] / K.R. McKeown, J. Robin, K. Kukich // Information Proc. & Management. – 1995.
15. Plaza, L. Concept-graph based Biomedical Automatic Summarization using Ontologies // Coling 2008: Proceedings of 3rd Textgraphs workshop on Graph-Based Algorithms in Natural Language Processing. – Manchester, 2008. – P. 53–56.
16. Radev, D.R., Hovy, E.H., McKeown, K. Introduction to the Special Issue on Summarization // Computational Linguistics. – 2002. – № 28 (4). – C. 399–408.
17. Salton, G., Singhal, A., Mitra, M. et al. Automatic Text Structuring and Summarization [Текст] / G. Salton, A. Singhal, M. Mitra et al. // Information Proc. & Management. – 1997. – № 33(2). – P. 193–207.
18. Strzalkowski, T., Stein, G. C., Wang, J. et al. A robust practical text summarizer [Текст] / T. Strzalkowski, G. C. Stein, J. Wang et al. // In Advances in Automatic Text Summarization, COLING-ACL, 1999. – P. 137-154.

19. Vaswani, A., Shazeer, N.M., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I. Attention Is All You Need // 31st Conference on Neural Information Processing Systems (NIPS). – 2017. – P. 5998-6008.
20. Wong, Kam-Fai. Extractive summarization using supervised and semi-supervised learning // Proceedings of the 22nd International Conference on Computational Linguistics (Coling 2008). – Manchester, 2008. – P. 985–992.
21. Yu, J., Reiter, E., Hunter, J., Mellish, C. Choosing the content of textual summaries of large timeseries data sets // Natural Language Engineering. – 2007. – Vol. 13, № 1. – P. 25–49.
22. Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., Zettlemoyer, L. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension [Текст] / M. Lewis et al. // Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). – 2020. – С. 7871–7880.
23. Zhang, J., Zhao, Y., Saleh, M., Liu, P. J. PEGASUS: Pre-training with Extracted Gap-sentences for Abstractive Summarization [Текст] / J. Zhang, Y. Zhao, M. Saleh, P. J. Liu // In Proc. of the 37th International Conference on Machine Learning (ICML). – 2020. – С. 11328–11339.
24. Beltagy, I., Peters, M. E., Cohan, A. Longformer: The Long-Document Transformer [Электронный ресурс] / I. Beltagy, M. E. Peters, A. Cohan // arXiv preprint arXiv:2004.05150. – 2020. – Режим доступа: <https://arxiv.org/abs/2004.05150> (дата обращения: 01.05.2025).
25. Liu, S., Cao, J., Yang, R., Wen, Z. Highlight-Transformer: Leveraging Key Phrase Aware Attention to Improve Abstractive Multi-Document Summarization [Текст] / S. Liu, J. Cao, R. Yang, Z. Wen // Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. – 2021. – С. 5021–5027.
26. Manakul, P., Gales, M. J. F. Long-Span Summarization via Local Attention and Content Selection [Электронный ресурс] / P. Manakul, M. J. F. Gales // arXiv preprint arXiv:2105.03801. – 2021. – Режим доступа: <https://arxiv.org/abs/2105.03801> (дата обращения: 01.05.2025).

27. Jiang, Y., Celikyilmaz, A., Smolensky, P., Soulos, P., Rao, S., Palangi, H., Fernandez, R., Smith, C., Bansal, M., Gao, J. Enriching Transformers with Structured Tensor-Product Representations for Abstractive Summarization [Электронный ресурс] / Y. Jiang et al. // arXiv preprint arXiv:2106.01317. – 2021. – Режим доступа: <https://arxiv.org/abs/2106.01317> (дата обращения: 01.05.2025).
28. Liu, Y., Zhang, J.-G., Wan, Y., Xia, C., He, L., Yu, P. S. HETFORMER: Heterogeneous Transformer with Sparse Attention for Long-Text Extractive Summarization [Электронный ресурс] / Y. Liu et al. // arXiv preprint arXiv:2110.06388. – 2021. – Режим доступа: <https://arxiv.org/abs/2110.06388> (дата обращения: 01.05.2025).
29. Liu, Y., Liu, P. L. SimCLS: A Simple Framework for Contrastive Learning of Abstractive Summarization [Текст] / Y. Liu, P. L. Liu // Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). – 2021. – С. 1065–1072.
30. Liu, Y., Liu, P., Radev, D., Neubig, G. BRIO: Bringing Order to Abstractive Summarization [Текст] / Y. Liu, P. Liu, D. Radev, G. Neubig // Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). – Dublin, Ireland, May 22–27, 2022. – С. 2890–2903.
31. Huang, L., Cao, S., Parulian, N., Ji, H., Wang, L. Efficient Attentions for Long Document Summarization (HEPOS) [Текст] / L. Huang et al. // NAACL-HLT 2021. – 2021. – С. 1419–1436.
32. Liu, Y., Dou, Z.-Y., Liu, P. RefSum: Refactoring Neural Summarization [Текст] / Y. Liu, Z. Y. Dou, P. Liu // NAACL-HLT 2021. – 2021. – С. 1437–1448.
33. Huang, D., Cui, L., Yang, S., Bao, G., Wang, K., Xie, J., Zhang, Y. What Have We Achieved on Text Summarization? [Электронный ресурс] / D. Huang et al. // arXiv preprint arXiv:2010.04529. – 2020. – Режим доступа: <https://arxiv.org/abs/2010.04529> (дата обращения: 01.05.2025).
34. Cao, M. A Survey on Neural Abstractive Summarization Methods and Factual Consistency of Summarization [Электронный ресурс] / M. Cao // arXiv preprint

arXiv:2204.09519. – 2022. – Режим доступа: <https://arxiv.org/abs/2204.09519> (дата обращения: 01.05.2025).

35. Rennard, V., Shang, G., Hunter, J., Vazirgiannis, M. Abstractive Meeting Summarization: A Survey [Электронный ресурс] / V. Rennard et al. // arXiv preprint arXiv:2208.04163. – 2022. – Режим доступа: <https://arxiv.org/abs/2208.04163> (дата обращения: 01.05.2025).

36. Huang, Y., Feng, X., Feng, X., Qin, B. The Factual Inconsistency Problem in Abstractive Text Summarization: A Survey [Электронный ресурс] / Y. Huang et al. // arXiv preprint arXiv:2104.14839. – 2021. – Режим доступа: <https://arxiv.org/abs/2104.14839> (дата обращения: 01.05.2025).

37. Shakil, H., Farooq, A., Kalita, J. Abstractive Text Summarization: State of the Art, Challenges, and Improvements [Электронный ресурс] / H. Shakil, A. Farooq, J. Kalita // arXiv preprint arXiv:2409.02413. – 2024. – Режим доступа: <https://arxiv.org/abs/2409.02413> (дата обращения: 01.05.2025).

38. Nnadi, G. O., Bertini, F. Survey on Abstractive Text Summarization: Dataset, Models, and Metrics [Электронный ресурс] / G. O. Nnadi, F. Bertini // arXiv preprint arXiv:2412.17165. – 2024. – Режим доступа: <https://arxiv.org/abs/2412.17165> (дата обращения: 01.05.2025).

39. Jin, H., Zhang, Y., Meng, D., Wang, J., Tan, J. A Comprehensive Survey on Process-Oriented Automatic Text Summarization with Exploration of LLM-Based Methods [Электронный ресурс] / H. Jin et al. // arXiv preprint arXiv:2403.02901. – 2024. – Режим доступа: <https://arxiv.org/abs/2403.02901> (дата обращения: 01.05.2025).

40. Sunusi, Y., Omar, N., Zakaria, L. Q. Exploring Abstractive Text Summarization: Methods, Datasets, Evaluation, and Emerging Challenges [Текст] / Y. Sunusi, N. Omar, L. Q. Zakaria // International Journal of Advanced Computer Science and Applications. – 2024. – Т. 15, № 7. – С. 1–12.

ПРИЛОЖЕНИЕ

Ссылка на код для доступа к LLM через API:

<https://colab.research.google.com/drive/1r-OsBHheDc4O0EX0z8Co8x1dY5qNRWNo?usp=sharing>

Ссылка на код для использования моделей с платформы Hugging Face:

<https://colab.research.google.com/drive/1eImNA9FXPKNmWHzWd0eVNU2jac9VexuS?usp=sharing>

Ссылка на код для всех визуализаций в работе и расчёта метрик:

https://colab.research.google.com/drive/1GTQlOMt4-XFKjHJRpTFhOrXpcew47_8Z?usp=sharing